

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH

ĐIỂM SỐ	ĐIỂM CHỮ	Cán bộ chấm thi 1 <i>(Kí, ghi rõ họ tên)</i>	Cán bộ chấm thi 2 <i>(Kí, ghi rõ họ tên)</i>

TIỂU LUẬN HỌC PHẦN
CƠ SỞ DỮ LIỆU NÂNG CAO

KHAI PHÁ LỖI SAI VÀ MẪU HÌNH SAI LẦM
TRONG KIỂM TRA ĐÁNH GIÁ DẠNG CÂU HỎI TỰ LUẬN

Ngành: Khoa học máy tính

Khóa: 36 (2025 – 2027)

Giảng viên giảng dạy: TS. Trần Sơn Hải

Người thực hiện: Võ Phú Vinh – KHMT836036

Thành phố Hồ Chí Minh, ngày 01 tháng 05 năm 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH



TIỂU LUẬN HỌC PHẦN
CƠ SỞ DỮ LIỆU NÂNG CAO

KHAI PHÁ LỖI SAI VÀ MẪU HÌNH SAI LẦM
TRONG KIỂM TRA ĐÁNH GIÁ DẠNG CÂU HỎI TỰ LUẬN

Ngành: Khoa học máy tính

Khóa: 36 (2025 – 2027)

Giảng viên giảng dạy: TS. Trần Sơn Hải

Người thực hiện: Võ Phú Vinh – KHMT836036

Thành phố Hồ Chí Minh, ngày 01 tháng 05 năm 2026

LỜI CAM ĐOAN

Tôi xin cam đoan tiểu luận “**Khai phá lỗi sai và mẫu hình sai lầm trong kiểm tra đánh giá dạng câu hỏi tự luận**” là kết quả nghiên cứu, tổng hợp và thực hiện của cá nhân tôi trong khuôn khổ học phần **Cơ sở dữ liệu nâng cao**.

Các nội dung trình bày trong tiểu luận được xây dựng dựa trên quá trình tìm hiểu cơ sở lý thuyết, phân tích các nghiên cứu liên quan, thiết kế pipeline thực nghiệm, xử lý dữ liệu, đánh giá kết quả và triển khai demo minh họa. Những tài liệu, công trình nghiên cứu, bộ dữ liệu và công cụ được sử dụng trong tiểu luận đều được trích dẫn đầy đủ trong phần tài liệu tham khảo.

Tôi xin chịu trách nhiệm về tính trung thực, tính nhất quán và tính học thuật của toàn bộ nội dung được trình bày trong tiểu luận này.

LỜI CẢM ƠN

Tôi xin trân trọng gửi lời cảm ơn đến **TS. Trần Sơn Hải**, giảng viên phụ trách học phần **Cơ sở dữ liệu nâng cao**, đã tận tình giảng dạy, định hướng và góp ý trong quá trình tôi thực hiện tiểu luận. Những chỉ dẫn của thầy đã giúp tôi hiểu rõ hơn cách tiếp cận một vấn đề nghiên cứu, cách tổ chức nội dung học thuật, cũng như cách kết hợp giữa cơ sở lý thuyết, thực nghiệm và triển khai hệ thống minh họa.

Tôi cũng xin gửi lời cảm ơn đến các tác giả, cộng đồng nghiên cứu và cộng đồng mã nguồn mở đã công bố các công trình, bộ dữ liệu và công cụ liên quan đến **Automatic Short Answer Grading, Educational Data Mining, Sentence-BERT, UMAP, HDBSCAN và BERTopic**. Đây là những nền tảng quan trọng giúp tôi có cơ sở để xây dựng, thực nghiệm và hoàn thiện đề tài.

Do giới hạn về thời gian, kinh nghiệm nghiên cứu và phạm vi học phần, tiểu luận khó tránh khỏi những thiếu sót. Tôi rất mong nhận được sự góp ý của thầy để có thể tiếp tục hoàn thiện nội dung nghiên cứu trong các hướng phát triển sau.

TÓM TẮT

Tiểu luận này trình bày một hướng tiếp cận **khai phá lỗi sai và mẫu hình sai lầm** trong **kiểm tra đánh giá dạng câu hỏi tự luận**, tập trung vào các câu trả lời ngắn của sinh viên. Thay vì chỉ dừng lại ở việc phân loại câu trả lời là đúng, sai hoặc đúng một phần như các hệ thống **Automatic Short Answer Grading** truyền thống [6], nghiên cứu hướng đến việc phát hiện các nhóm câu trả lời sai có cùng **nguyên nhân gốc rễ**. Việc nhận diện các nhóm sai lầm này có thể hỗ trợ giáo viên hiểu rõ hơn những nhầm lẫn phổ biến của người học, từ đó điều chỉnh nội dung giảng dạy và phân hồi học tập phù hợp hơn.

Phương pháp đề xuất sử dụng **Sentence-BERT** để biểu diễn ngữ nghĩa câu hỏi và câu trả lời [1], **UMAP** để giảm chiều dữ liệu [2], kết hợp với các phương pháp phân cụm như **KMeans**, **HDBSCAN** [3] và **BERTopic-style** [4] để phát hiện các nhóm lỗi sai. Nghiên cứu tiến hành so sánh có hệ thống **3 chiến lược embedding $\times$ 3 phương pháp phân cụm = 9 cấu hình**. Dữ liệu thực nghiệm gồm hai nguồn chính là **SciEntsBank** [5] và **Data_Generate**.

Chất lượng phân cụm được đánh giá bằng các chỉ số nội tại gồm **Silhouette** [8], **Calinski-Harabasz** [9], **Davies-Bouldin** [10], và các chỉ số ngoại tại gồm **NMI**, **ARI**, **Purity** và **V-measure**, trong đó V-measure được sử dụng như một thước đo đánh giá phân cụm dựa trên entropy có điều kiện [11]. Kết quả thực nghiệm cho thấy cấu hình **C6 – question_answer + BERTopic-style** đạt hiệu quả tốt nhất, với **Silhouette = 0.42**, **NMI = 0.63**, **ARI = 0.49**, **Purity = 0.72** và **V-measure = 0.61**. Bên cạnh phần thực nghiệm, tiểu luận cũng xây dựng một ứng dụng demo bằng **Next.js**, triển khai trên **Vercel**, nhằm trực quan hóa bản đồ cụm lỗi sai, so sánh các cấu hình và hiển thị ví dụ câu trả lời đại diện theo từng nhóm sai lầm.

Từ khóa: Kiểm tra đánh giá tự luận, Automatic Short Answer Grading, Misconception Mining, Educational Data Mining, Sentence-BERT, UMAP, HDBSCAN, BERTopic.

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Tiếng Anh	Ý nghĩa trong tiểu luận
ASAG	Automatic Short Answer Grading	Chấm điểm tự động câu trả lời ngắn
EDM	Educational Data Mining	Khai phá dữ liệu giáo dục
NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
SBERT	Sentence-BERT	Mô hình biểu diễn ngữ nghĩa câu
UMAP	Uniform Manifold Approximation and Projection	Thuật toán giảm chiều dữ liệu
HDBSCAN	Hierarchical Density-Based Spatial Clustering of Applications with Noise	Thuật toán phân cụm dựa trên mật độ
c-TF-IDF	class-based Term Frequency-Inverse Document Frequency	Kỹ thuật trích xuất từ khóa đại diện theo cụm
NMI	Normalized Mutual Information	Chỉ số đánh giá mức độ tương đồng giữa nhãn cụm và nhãn thật
ARI	Adjusted Rand Index	Chỉ số đánh giá phân cụm có điều chỉnh theo ngẫu nhiên

DANH MỤC BẢNG BIỂU VÀ HÌNH ẢNH

Danh mục bảng

Mã bảng	Tên bảng
Bảng 1.1	Tổng quan nguồn dữ liệu sử dụng trong nghiên cứu
Bảng 2.1	Tham số UMAP sử dụng trong pipeline
Bảng 2.2	Tham số HDBSCAN sử dụng trong pipeline
Bảng 4.1	Ma trận 9 cấu hình thí nghiệm
Bảng 4.2	Kết quả intrinsic metrics ở mức global
Bảng 4.3	Kết quả extrinsic metrics trên Data_Generate
Bảng 4.4	Kết quả theo granularity của cấu hình C6
Bảng 5.1	Công nghệ sử dụng trong ứng dụng demo
Bảng 5.2	Các nhóm trường chính trong UnifiedRecord
Bảng 5.3	Ma trận cấu hình thực nghiệm trong phần mô tả hệ thống

Danh mục hình

Mã hình	Tên hình
Hình 2.1	Pipeline tổng quát của hệ thống misconception mining
Hình 2.2	Ba chiến lược embedding: answer_only, question_answer, full_triplet
Hình 2.3	Luồng SBERT → UMAP → HDBSCAN → c-TF-IDF trong BERTopic-style pipeline
Hình 4.1	Biểu đồ so sánh Silhouette của 9 cấu hình
Hình 4.2	Biểu đồ so sánh NMI, ARI, Purity và V-measure của 9 cấu hình
Hình 5.1	Kiến trúc tổng quan ứng dụng demo và triển khai hệ thống
Hình 5.2	Giao diện tổng quan demo Misconception Mining
Hình 5.3	Giao diện bản đồ cụm lỗi sai UMAP và chi tiết nhóm

MỤC LỤC

Lời Cam Đoan	i
Lời Cảm Ơn	ii
Tóm tắt	iii
Danh Mục Từ Viết Tắt	iv
Danh Mục Bảng Biểu Và Hình Ảnh	v
1 Mở đầu	1
1.1 Tính cấp thiết của đề tài	1
1.2 Mục tiêu nghiên cứu	1
1.3 Đối tượng và phạm vi nghiên cứu	1
1.4 Phương pháp nghiên cứu	2
1.5 Câu hỏi nghiên cứu	2
1.6 Đóng góp của đề tài	3
1.7 Bố cục tiểu luận	3
2 Cơ sở lý thuyết và phương pháp	4
2.1 Hình thức hóa bài toán	4
2.2 Các chiến lược embedding	4
2.3 Giảm chiều bằng UMAP	6
2.4 Các phương pháp phân cụm	6
2.5 Trích xuất từ khóa bằng c-TF-IDF	7
2.6 Tổng kết chương	8
3 Đánh giá chất lượng phân cụm	9
3.1 Mục tiêu đánh giá	9
3.2 Nhóm chỉ số nội tại	9
3.3 Nhóm chỉ số ngoại tại	9
3.4 Xử lý điểm nhiễu và cụm nhỏ	9
3.5 Cách diễn giải kết quả đánh giá	10
4 Thí nghiệm và kết quả	11
4.1 Thiết lập thực nghiệm	11
4.2 Ma trận thí nghiệm	11
4.3 Kết quả intrinsic metrics	12
4.4 Kết quả extrinsic metrics	13
4.5 Kết quả theo granularity	14
4.6 Thảo luận	14

5	Ứng dụng demo và mô tả triển khai hệ thống	16
5.1	Liên kết GitHub và demo triển khai	16
5.2	Kiến trúc hệ thống demo	16
5.3	Mô tả hệ thống và tư liệu đi kèm mã nguồn	17
5.3.1	Tổng quan đề tài	17
5.3.2	Cấu trúc thư mục dự án	18
5.3.3	Pipeline xử lý dữ liệu	18
5.3.4	Cơ sở dữ liệu và schema chuẩn hóa	19
5.3.5	Dữ liệu mẫu	20
5.3.6	Cấu hình thực nghiệm	21
5.3.7	Kết quả đầu ra	21
5.3.8	Vai trò của phần mô tả hệ thống	22
5.4	Mô tả giao diện demo và trực quan hóa kết quả	22
6	Kết luận và hướng phát triển	25
6.1	Kết luận	25
6.2	Hạn chế	25
6.3	Hướng phát triển	25
	Tài liệu tham khảo	26
A	Liên kết mã nguồn và demo	27

CHƯƠNG 1 : MỞ ĐẦU

1.1 Tính cấp thiết của đề tài

Trong hệ thống giáo dục hiện đại, đánh giá năng lực người học thông qua câu trả lời ngắn là một phương pháp quan trọng vì người học phải tự diễn đạt kiến thức bằng ngôn ngữ của mình. Khác với câu hỏi trắc nghiệm, câu trả lời ngắn phản ánh rõ hơn mức độ hiểu khái niệm, khả năng lập luận và cách sinh viên tổ chức tri thức. Tuy nhiên, khi số lượng câu trả lời tăng lên, việc chấm điểm và phân tích thủ công trở nên tốn nhiều thời gian, dễ thiếu nhất quán giữa các giáo viên chấm bài.

Các hệ thống Automatic Short Answer Grading (ASAG) được phát triển nhằm tự động đánh giá mức độ đúng đắn của câu trả lời [6]. Một hệ thống ASAG điển hình nhận đầu vào gồm câu hỏi, câu trả lời tham chiếu và câu trả lời của sinh viên, sau đó dự đoán nhãn như `correct`, `partially_correct` hoặc `incorrect`. Tuy vậy, phần lớn hệ thống ASAG chỉ dừng lại ở việc xác định câu trả lời đúng hay sai, trong khi chưa phân tích sâu vì sao sinh viên sai và các lỗi sai đó có lặp lại thành mẫu hình hay không.

Đây là lý do đề tài tập trung vào bài toán Misconception Mining – khai phá lỗi sai và mẫu hình sai lầm trong câu trả lời sinh viên. Các nghiên cứu gần đây cũng cho thấy mô hình ngôn ngữ dựa trên BERT có thể được sử dụng để phát hiện misconception trong phản hồi của người học [13]. Thay vì chỉ gán nhãn đúng/sai, hệ thống cần phát hiện các nhóm câu trả lời sai có cùng nguyên nhân gốc rễ. Ví dụ, nếu nhiều sinh viên cùng nhầm lẫn giữa “lực” và “năng lượng”, giáo viên có thể xem đó là một misconception phổ biến và điều chỉnh bài giảng phù hợp hơn.

Bài toán này có ý nghĩa thực tiễn trong bối cảnh dữ liệu giáo dục ngày càng lớn, đặc biệt trên các hệ thống LMS, MOOC hoặc nền tảng kiểm tra trực tuyến. Các hướng nghiên cứu về learning analytics cho thấy việc phân tích dữ liệu học tập có thể hỗ trợ hiểu rõ hành vi, năng lực và khó khăn của người học ở quy mô lớn [12]. Khi số lượng câu trả lời lên đến hàng chục nghìn hoặc hàng trăm nghìn mẫu, việc khai phá lỗi sai bằng các kỹ thuật NLP, sentence embedding, giảm chiều và phân cụm không giám sát trở thành hướng tiếp cận có khả năng mở rộng và phù hợp với nhu cầu thực tế.

1.2 Mục tiêu nghiên cứu

Mục tiêu tổng quát của tiểu luận là xây dựng và đánh giá một pipeline tự động để khai phá các mẫu hình sai lầm trong câu trả lời sinh viên. Pipeline sử dụng kết hợp **Sentence-BERT (SBERT)** để biểu diễn ngữ nghĩa, **UMAP** để giảm chiều dữ liệu và các thuật toán phân cụm như **KMeans**, **HDBSCAN** và **BERTopic-style** để phát hiện nhóm lỗi sai.

Nghiên cứu thực hiện so sánh có hệ thống **3 chiến lược embedding $\times$ 3 phương pháp phân cụm = 9 cấu hình**. Ba chiến lược embedding gồm: `answer_only`, `question_answer` và `full_triplet`. Ba phương pháp phân cụm gồm: **KMeans**, **UMAP + HDBSCAN** và **BERTopic-style**.

Các nhiệm vụ cụ thể gồm: thiết kế module embedding, triển khai phân cụm, xây dựng hệ thống đánh giá bằng metric nội tại và ngoại tại, thực hiện thí nghiệm trên dữ liệu thực nghiệm, đồng thời phát triển giao diện demo giúp trực quan hóa kết quả phân cụm.

1.3 Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu là các câu trả lời sai của sinh viên trong bài kiểm tra câu trả lời ngắn thuộc lĩnh vực khoa học tự nhiên. Dữ liệu sử dụng gồm hai nguồn chính, trong đó SciEntsBank là bộ dữ liệu benchmark thường được sử dụng trong các nghiên cứu phân tích câu trả lời ngắn [5].

Bảng 1.1. Tổng quan nguồn dữ liệu sử dụng trong nghiên cứu

Nguồn dữ liệu	Quy mô	Đặc điểm chính	Vai trò trong nghiên cứu
SciEntsBank	Khoảng 10,000 mẫu	Bộ dữ liệu benchmark công khai, nhãn 5-way gồm ‘correct’, ‘partially_correct_incomplete’, ‘contradictory’, ‘irrelevant’, ‘non_domain’	Dữ liệu nền cho bài toán ASAG và lọc câu trả lời sai
Data_Generate	10,000 mẫu	Dữ liệu tổng hợp bằng LLM, có ‘misconception_tags’, ‘misconception_inventory’, ‘missing_concepts’, ‘extra_incorrect_claims’	Dùng làm gold labels cho đánh giá extrinsic

Phạm vi nghiên cứu được giới hạn ở các bản ghi có label_5way thuộc tập {partially_correct_incomplete, contradictory, irrelevant}. Mô hình embedding sử dụng cố định là all-MiniLM-L6-v2 để đảm bảo tính công bằng khi so sánh các chiến lược. Thí nghiệm được triển khai theo ba mức độ chi tiết: per-question, per-domain và global. Chất lượng phân cụm được đánh giá bằng các metric nội tại gồm Silhouette, Calinski-Harabasz, Davies-Bouldin và các metric ngoại tại gồm NMI, ARI, Purity, V-measure.

1.4 Phương pháp nghiên cứu

Đề tài sử dụng phương pháp nghiên cứu thực nghiệm kết hợp với phân tích định lượng. Trước hết, dữ liệu câu trả lời ngắn được chuẩn hóa về cùng một schema để bảo đảm các nguồn dữ liệu khác nhau có thể được xử lý thống nhất. Sau đó, các câu trả lời sai được lọc dựa trên nhãn label_5way, tập trung vào ba nhóm lỗi chính gồm partially_correct_incomplete, contradictory và irrelevant.

Ở giai đoạn biểu diễn dữ liệu, nghiên cứu sử dụng mô hình SBERT all-MiniLM-L6-v2 để chuyển văn bản thành vector ngữ nghĩa 384 chiều. Ba chiến lược embedding được xây dựng nhằm đánh giá tác động của ngữ cảnh đầu vào: chỉ dùng câu trả lời sinh viên, kết hợp câu hỏi với câu trả lời sinh viên, và kết hợp đầy đủ câu hỏi, câu trả lời tham chiếu cùng câu trả lời sinh viên.

Ở giai đoạn phân cụm, nghiên cứu so sánh KMeans, UMAP + HDBSCAN và BERTopic-style. Việc so sánh này cho phép đánh giá sự khác biệt giữa phân cụm dựa trên centroid, phân cụm dựa trên mật độ và pipeline có khả năng diễn giải bằng từ khóa. Kết quả được đánh giá bằng các chỉ số nội tại và ngoại tại, sau đó được trực quan hóa thông qua ứng dụng demo Next.js.

1.5 Câu hỏi nghiên cứu

Từ mục tiêu nghiên cứu đã nêu, tiểu luận tập trung trả lời ba câu hỏi chính:

Việc bổ sung ngữ cảnh câu hỏi và câu trả lời tham chiếu vào embedding có cải thiện chất lượng phân cụm lỗi sai hay không?

Trong ba phương pháp KMeans, UMAP + HDBSCAN và BERTopic-style, phương pháp nào phù hợp hơn với bài toán khai phá misconception trong câu trả lời ngắn?

Kết quả phân cụm có thể được diễn giải và trực quan hóa như thế nào để hỗ trợ giáo viên nhận diện các mẫu hình sai lầm phổ biến của sinh viên?

Các câu hỏi này giúp định hướng thiết kế thí nghiệm, lựa chọn metric đánh giá và cách trình bày kết quả trong các chương sau.

1.6 Đóng góp của đề tài

Đề tài có ba đóng góp chính. Thứ nhất, nghiên cứu xây dựng một pipeline end-to-end cho bài toán misconception mining, bao gồm chuẩn hóa dữ liệu, embedding, giảm chiều, phân cụm, đánh giá và trực quan hóa kết quả. Thứ hai, nghiên cứu thực hiện so sánh có hệ thống 9 cấu hình được tạo từ 3 chiến lược embedding và 3 phương pháp phân cụm, từ đó xác định cấu hình phù hợp nhất cho dữ liệu thực nghiệm. Thứ ba, đề tài triển khai một ứng dụng demo trực quan hóa kết quả, giúp người đọc quan sát bản đồ cụm lỗi sai, so sánh cấu hình và xem ví dụ câu trả lời đại diện theo từng nhóm misconception.

Các đóng góp này cho thấy đề tài không chỉ có ý nghĩa về mặt thuật toán mà còn có giá trị thực tiễn trong việc hỗ trợ giáo viên và nhà nghiên cứu giáo dục phân tích lỗi sai của sinh viên ở quy mô lớn.

1.7 Bố cục tiểu luận

Tiểu luận được tổ chức thành sáu chương chính. **Chương 1** trình bày tính cấp thiết, mục tiêu, đối tượng và phạm vi nghiên cứu. **Chương 2** trình bày cơ sở lý thuyết và phương pháp, bao gồm hình thức hóa bài toán, các chiến lược embedding, UMAP và các phương pháp phân cụm. **Chương 3** mô tả hệ thống đánh giá chất lượng phân cụm bằng các metric nội tại và ngoại tại. **Chương 4** trình bày thiết kế thí nghiệm, kết quả so sánh 9 cấu hình và thảo luận kết quả. **Chương 5** mô tả ứng dụng demo, kiến trúc triển khai hệ thống, cấu trúc dữ liệu và các tư liệu đi kèm mã nguồn. **Chương 6** tổng kết kết quả đạt được, nêu hạn chế và định hướng phát triển tiếp theo.


CHƯƠNG 2 : CƠ SỞ LÝ THUYẾT VÀ PHƯƠNG PHÁP

2.1 Hình thức hóa bài toán

Cho tập dữ liệu D gồm N bản ghi, mỗi bản ghi là một bộ bốn:

$$D = \{(q_i, r_i, s_i, y_i)\}_{i=1}^N \quad (2.1)$$

Trong đó, q_i là câu hỏi, r_i là câu trả lời tham chiếu, s_i là câu trả lời sinh viên và y_i là nhãn phân loại 5-way. Mục tiêu của bài toán là tìm một hàm phân cụm $f : D \rightarrow \{1, 2, \dots, K\}$ sao cho các câu trả lời sai có cùng nguyên nhân gốc rễ được đưa vào cùng một cụm. Với KMeans, số cụm K được xác định trước; với HDBSCAN, số cụm được tự động phát hiện dựa trên mật độ dữ liệu.



Hình 2.1. Pipeline tổng quát của hệ thống misconception mining

2.2 Các chiến lược embedding

Nghiên cứu sử dụng SBERT all-MiniLM-L6-v2, mô hình có vector đầu ra 384 chiều, phù hợp cho bài toán biểu diễn câu với tốc độ xử lý nhanh [1], [14]. Ba chiến lược embedding được thiết kế nhằm kiểm tra mức độ ảnh hưởng của ngữ cảnh đầu vào đến chất lượng phân cụm.

Strategy A – ‘answer_only’: chỉ đưa câu trả lời sinh viên vào mô hình embedding.

$$e_i = \text{SBERT}(s_i)$$

Chiến lược này đơn giản và tập trung vào nội dung sinh viên viết. Tuy nhiên, nó có thể nhóm chung các câu trả lời giống nhau về từ vựng nhưng thuộc các câu hỏi khác nhau.

Strategy B – ‘question_answer’: kết hợp câu hỏi và câu trả lời sinh viên.


$$e_i = \text{SBERT}(q_i \oplus s_i)$$

Chiến lược này bổ sung ngữ cảnh câu hỏi, giúp mô hình phân biệt các câu trả lời có bề mặt giống nhau nhưng ý nghĩa khác nhau tùy theo câu hỏi.

Strategy C – ‘full_triplet’: kết hợp câu hỏi, câu trả lời tham chiếu và câu trả lời sinh viên.

$$e_i = \text{SBERT}(q_i \oplus r_i \oplus s_i)$$

Chiến lược này cung cấp đầy đủ ngữ cảnh nhất, nhưng cũng có nguy cơ làm câu trả lời tham chiếu lẫn át thông tin sai lệch trong câu trả lời sinh viên.



Hình 2.2. Ba chiến lược embedding trong nghiên cứu

2.3 Giảm chiều bằng UMAP

UMAP được sử dụng để giảm chiều embedding từ không gian 384D xuống 5D trước khi phân cụm [2]. Việc giảm chiều giúp giảm nhiễu, làm nổi bật cấu trúc cục bộ của dữ liệu và hỗ trợ HDBSCAN phát hiện các cụm có mật độ khác nhau.

Bảng 2.1. Tham số UMAP sử dụng trong pipeline

Tham số	Giá trị	Ý nghĩa
‘n_components‘	5	Số chiều đầu ra cho phân cụm; 2D có thể dùng cho trực quan hóa
‘n_neighbors‘	15	Số lượng lân cận xét đến khi xây dựng cấu trúc manifold
‘min_dist‘	0.1	Khoảng cách tối thiểu giữa các điểm trong không gian thấp chiều
‘metric‘	cosine	Khoảng cách phù hợp với sentence embeddings
‘random_state‘	42	Đảm bảo khả năng tái lập kết quả

2.4 Các phương pháp phân cụm


KMeans được dùng như baseline vì đây là thuật toán phân cụm phổ biến dựa trên centroid. Trong nghiên cứu, KMeans sử dụng n_clusters = 10, n_init = 10, max_iter = 300.

HDBSCAN được sử dụng vì không yêu cầu xác định trước số cụm và có khả năng nhận diện noise points với nhãn -1 [3]. Điều này phù hợp với bài toán misconception mining, vì không phải mọi câu trả lời sai đều tạo thành một mẫu hình sai lầm phổ biến.

Bảng 2.2. Tham số HDBSCAN sử dụng trong pipeline

Tham số	Giá trị	Ý nghĩa
‘min_cluster_size‘	5	Kích thước tối thiểu của một cụm
‘min_samples‘	3	Số mẫu tối thiểu để một điểm được xem là core point
‘cluster_selection_method‘	eom	Phương pháp chọn cụm theo độ ổn định

BERTopic-style pipeline kết hợp SBERT → UMAP → HDBSCAN → c-TF-IDF, dựa trên ý tưởng topic modeling hiện đại của BERTopic [4]. Điểm mạnh của pipeline này là vừa phát hiện cụm, vừa trích xuất từ khóa đại diện cho từng cụm, giúp giáo viên hoặc nhà nghiên cứu dễ diễn giải nội dung mỗi nhóm lỗi sai.



Hình 2.3. Luồng xử lý của BERTopic-style pipeline

2.5 Trích xuất từ khóa bằng c-TF-IDF

Trong BERTopic-style pipeline, sau khi HDBSCAN tạo ra các cụm, hệ thống cần một cơ chế để diễn giải nội dung của từng cụm. Nếu chỉ có nhãn cụm như 0, 1, 2, kết quả phân cụm sẽ khó sử dụng trong bối cảnh giáo dục vì giáo viên không biết mỗi cụm đại diện cho loại lỗi sai nào. Vì vậy, nghiên cứu sử dụng **c-TF-IDF** để trích xuất các từ khóa đại diện cho từng cụm.

Khác với TF-IDF truyền thống, c-TF-IDF xem toàn bộ các văn bản trong cùng một cụm như một “tài liệu lớp” duy nhất. Từ đó, thuật toán xác định những từ hoặc cụm từ xuất hiện đặc trưng trong cụm này nhưng không phổ biến ở các cụm khác. Nhờ vậy, mỗi cụm lỗi sai có thể được mô tả bằng một nhóm từ khóa ngắn gọn, giúp người đọc nhanh chóng nhận diện nội dung chính của misconception.

Trong bài toán khai phá lỗi sai, c-TF-IDF có vai trò quan trọng ở khâu diễn giải. Ví dụ, một cụm có các từ khóa liên quan đến “force”, “energy”, “same” có thể gợi ý rằng sinh viên đang nhầm lẫn giữa lực và năng lượng; đây cũng là dạng nhầm lẫn khái niệm thường được quan tâm trong các nghiên cứu về nhận thức vật lý [6]. Các từ khóa này không thay thế đánh giá chuyên môn của giáo viên, nhưng đóng vai trò gợi ý ban đầu để giáo viên đọc nhanh các câu trả lời đại diện và xác định mẫu hình sai lầm.

2.6 Tổng kết chương

Chương 2 đã trình bày cơ sở lý thuyết và phương pháp chính của nghiên cứu. Bài toán misconception mining được hình thức hóa như một bài toán phân cụm các câu trả lời sai dựa trên biểu diễn ngữ nghĩa. Ba chiến lược embedding được xây dựng nhằm đánh giá tác động của ngữ cảnh đầu vào. UMAP được sử dụng để giảm chiều dữ liệu, trong khi KMeans, HDBSCAN và BERTopic-style được dùng để so sánh các cách phân cụm khác nhau. Cuối cùng, c-TF-IDF được sử dụng để hỗ trợ diễn giải cụm bằng từ khóa, giúp kết quả phân cụm có ý nghĩa hơn trong bối cảnh giáo dục.

CHƯƠNG 3 : ĐÁNH GIÁ CHẤT LƯỢNG PHÂN CỤM

3.1 Mục tiêu đánh giá

Mục tiêu của giai đoạn đánh giá là xác định mức độ phù hợp của các cụm lỗi sai được phát hiện bởi từng cấu hình thực nghiệm. Vì bài toán misconception mining không chỉ cần phân cụm dữ liệu, mà còn cần diễn giải các cụm theo ý nghĩa giáo dục, nghiên cứu sử dụng đồng thời hai nhóm chỉ số: **intrinsic metrics** và **extrinsic metrics**. Việc kết hợp hai nhóm chỉ số giúp đánh giá cả cấu trúc hình học của cụm trong không gian vector và mức độ tương ứng của cụm với nhãn misconception đã biết.

3.2 Nhóm chỉ số nội tại

Nhóm chỉ số nội tại không cần sử dụng nhãn thật. Các chỉ số này đánh giá chất lượng cụm dựa trên khoảng cách giữa các điểm dữ liệu trong cùng cụm và khoảng cách giữa các cụm khác nhau.

Silhouette Score đo mức độ một điểm dữ liệu phù hợp với cụm hiện tại so với các cụm khác. Giá trị càng cao cho thấy các cụm càng tách biệt và chặt chẽ hơn [8].

Calinski-Harabasz Index đo tỷ lệ giữa độ phân tán giữa các cụm và độ phân tán bên trong cụm. Giá trị càng cao thường thể hiện cấu trúc cụm rõ ràng hơn [9].

Davies-Bouldin Index đo mức độ tương đồng trung bình giữa mỗi cụm và cụm gần nhất với nó. Khác với hai chỉ số trên, Davies-Bouldin càng thấp thì chất lượng phân cụm càng tốt [10].

Trong nghiên cứu này, các chỉ số nội tại được dùng để so sánh nhanh độ chặt chẽ và độ tách biệt của các cấu hình C1–C9 ở mức global.

3.3 Nhóm chỉ số ngoại tại

Nhóm chỉ số ngoại tại cần sử dụng nhãn tham chiếu. Trong nghiên cứu này, nhãn tham chiếu được lấy từ trường misconception_tags của dữ liệu Data_Generate. Các chỉ số ngoại tại cho biết kết quả phân cụm có khớp với các nhóm misconception đã được gán nhãn hay không.

Normalized Mutual Information (NMI) đo lượng thông tin chung giữa nhãn cụm dự đoán và nhãn thật. Giá trị càng cao cho thấy kết quả phân cụm càng tương đồng với cấu trúc nhãn misconception.

Adjusted Rand Index (ARI) đo mức độ giống nhau giữa hai cách phân nhóm, có điều chỉnh theo khả năng trùng khớp ngẫu nhiên. ARI càng cao thì kết quả phân cụm càng đáng tin cậy.

Purity đo tỷ lệ mẫu thuộc nhãn phổ biến nhất trong mỗi cụm. Giá trị cao cho thấy mỗi cụm có xu hướng chứa các mẫu cùng loại misconception.

V-measure là trung bình điều hòa giữa homogeneity và completeness, phản ánh đồng thời việc một cụm có thuần nhất hay không và một nhãn thật có bị chia nhỏ thành quá nhiều cụm hay không [11].

3.4 Xử lý điểm nhiễu và cụm nhỏ

Đối với các phương pháp dựa trên mật độ như HDBSCAN và BERTopic-style, một số điểm dữ liệu có thể được gán nhãn -1, thể hiện rằng chúng không thuộc cụm rõ ràng nào. Các điểm này được xem là **noise points**. Trong bối cảnh giáo dục, noise points không nhất thiết là lỗi của mô hình, vì một số câu trả lời sai có thể mang tính cá biệt và không hình thành mẫu hình sai lầm phổ biến.

Khi phân tích kết quả, các điểm nhiễu cần được xem xét riêng để tránh làm sai lệch chất lượng của các cụm chính. Đồng thời, các cụm có quá ít mẫu cũng không nên được diễn giải như một misconception phổ biến, vì chúng

chưa đủ bằng chứng để đại diện cho một mẫu hình sai lầm có ý nghĩa giảng dạy.

3.5 Cách diễn giải kết quả đánh giá

Một cấu hình được xem là tốt nếu đồng thời đạt kết quả khả quan ở cả hai nhóm chỉ số. Về mặt nội tại, cấu hình đó cần có Silhouette và Calinski-Harabasz cao, Davies-Bouldin thấp. Về mặt ngoại tại, cấu hình đó cần có NMI, ARI, Purity và V-measure cao. Tuy nhiên, trong bài toán misconception mining, chỉ số định lượng chỉ là một phần của đánh giá. Kết quả phân cụm còn cần có khả năng diễn giải bằng từ khóa, ví dụ câu trả lời đại diện và ý nghĩa sự phạm của từng nhóm lỗi sai.

Do đó, nghiên cứu không chỉ chọn cấu hình dựa trên điểm số, mà còn ưu tiên cấu hình có khả năng hỗ trợ giải thích cụm. Đây là lý do BERTopic-style được đưa vào so sánh, vì ngoài việc phân cụm, phương pháp này còn trích xuất từ khóa đại diện bằng c-TF-IDF.

CHƯƠNG 4 : THÍ NGHIỆM VÀ KẾT QUẢ

4.1 Thiết lập thực nghiệm

Thí nghiệm được thiết kế nhằm so sánh ảnh hưởng của chiến lược embedding và phương pháp phân cụm đến chất lượng khai phá misconception. Để bảo đảm tính công bằng, các cấu hình đều sử dụng cùng backbone embedding là all-MiniLM-L6-v2 và cùng random seed là 42. Các siêu tham số chính của UMAP, HDBSCAN và KMeans được giữ cố định theo cấu hình đã trình bày ở Chương 2.

Dữ liệu đầu vào được lọc để chỉ giữ lại các câu trả lời có nhãn label_5way thuộc ba nhóm lỗi sai: partially_correct_incomplete, contradictory và irrelevant. Các câu trả lời đúng hoặc không thuộc miền kiến thức đang xét không được đưa vào phân cụm vì không trực tiếp phục vụ mục tiêu khai phá mẫu hình sai lầm.

Kết quả được đánh giá ở hai góc độ. Thứ nhất, các chỉ số nội tại như Silhouette, Calinski-Harabasz và Davies-Bouldin được dùng để đánh giá cấu trúc cụm trong không gian vector. Thứ hai, các chỉ số ngoại tại như NMI, ARI, Purity và V-measure được dùng để so sánh nhãn cụm với misconception_tags trong Data_Generate. Ngoài ra, nghiên cứu còn đánh giá theo ba mức granularity gồm per_question, per_domain và global để xem mức độ phân tích ảnh hưởng như thế nào đến chất lượng cụm.

4.2 Ma trận thí nghiệm

Nghiên cứu thực hiện 9 cấu hình, tương ứng với 3 chiến lược embedding và 3 phương pháp phân cụm.

Bảng 4.1. Ma trận 9 cấu hình thí nghiệm

Config	Strategy	Method	UMAP/c-TF-IDF
C1	A – ‘answer_only’	KMeans (K=10)	Không
C2	A – ‘answer_only’	UMAP + HDBSCAN	Có UMAP 5D
C3	A – ‘answer_only’	BERTopic-style	Có UMAP 5D + c-TF-IDF
C4	B – ‘question_answer’	KMeans (K=10)	Không
C5	B – ‘question_answer’	UMAP + HDBSCAN	Có UMAP 5D
C6	B – ‘question_answer’	BERTopic-style	Có UMAP 5D + c-TF-IDF
C7	C – ‘full_triplet’	KMeans (K=10)	Không
C8	C – ‘full_triplet’	UMAP + HDBSCAN	Có UMAP 5D
C9	C – ‘full_triplet’	BERTopic-style	Có UMAP 5D + c-TF-IDF


Mỗi cấu hình được chạy với cùng random seed là 42 nhằm đảm bảo tính tái lập.

4.3 Kết quả intrinsic metrics

Bảng 4.2. Kết quả intrinsic metrics ở mức global

Config	Strategy	Method	Silhouette	CH Index	DB Index	K found
C1	answer_only	KMeans	0.15	45.2	2.31	10
C2	answer_only	HDBSCAN	0.28	62.8	1.87	7
C3	answer_only	BERTopic	0.29	64.1	1.82	7
C4	question_answer	KMeans	0.22	58.3	2.05	10
C5	question_answer	HDBSCAN	0.41	89.5	1.45	9
C6	question_answer	BERTopic	0.42	91.2	1.41	9
C7	full_triplet	KMeans	0.19	52.7	2.18	10
C8	full_triplet	HDBSCAN	0.38	82.1	1.56	8
C9	full_triplet	BERTopic	0.39	84.3	1.52	8

Kết quả cho thấy cấu hình **C6 – question_answer + BERTopic-style** đạt Silhouette cao nhất là **0.42**, CH Index cao nhất là **91.2** và DB Index thấp nhất là **1.41**. Điều này cho thấy việc kết hợp câu hỏi với câu trả lời sinh viên giúp mô hình tạo ra embedding có tính ngữ cảnh tốt hơn, trong khi BERTopic-style giúp cải thiện chất lượng cụm nhờ UMAP và HDBSCAN.




Hình 4.1. Biểu đồ so sánh Silhouette của 9 cấu hình

4.4 Kết quả extrinsic metrics

Bảng 4.3. Kết quả extrinsic metrics trên Data_Generate

Config	Strategy	Method	NMI	ARI	Purity	V-measure
C1	answer_only	KMeans	0.32	0.18	0.45	0.30
C2	answer_only	HDBSCAN	0.48	0.31	0.58	0.46
C3	answer_only	BERTopic	0.49	0.32	0.59	0.47
C4	question_answer	KMeans	0.45	0.28	0.55	0.43
C5	question_answer	HDBSCAN	0.62	0.48	0.71	0.60
C6	question_answer	BERTopic	0.63	0.49	0.72	0.61
C7	full_triplet	KMeans	0.41	0.25	0.52	0.39
C8	full_triplet	HDBSCAN	0.57	0.42	0.66	0.55
C9	full_triplet	BERTopic	0.58	0.43	0.67	0.56

Ở nhóm metric ngoại tại, C6 tiếp tục đạt kết quả tốt nhất với **NMI = 0.63**, **ARI = 0.49**, **Purity = 0.72** và **V-measure = 0.61**. Kết quả này củng cố nhận định rằng việc đưa câu hỏi vào embedding là đủ để bổ sung ngữ cảnh cần thiết, trong khi việc đưa thêm câu trả lời tham chiếu ở Strategy C có thể làm nhiễu biểu diễn của câu trả lời sai.



Hình 4.2. Biểu đồ so sánh NMI, ARI, Purity và V-measure của 9 cấu hình

4.5 Kết quả theo granularity

Bảng 4.4. Kết quả theo granularity của cấu hình C6

Granularity	Silhouette	NMI	ARI	Purity	Avg K
per_question	0.55	0.71	0.58	0.82	3.2
per_domain	0.48	0.65	0.52	0.75	6.8
global	0.42	0.63	0.49	0.72	9

Kết quả cho thấy per_question đạt điểm cao nhất vì phạm vi phân cụm hẹp, các câu trả lời trong cùng một câu hỏi có ngữ cảnh tương đồng hơn. Tuy nhiên, global vẫn có giá trị khi cần phát hiện các misconception tổng quát xuất hiện xuyên suốt nhiều câu hỏi hoặc nhiều lĩnh vực. per_domain là mức cân bằng giữa độ chi tiết và khả năng tổng quát hóa.

4.6 Thảo luận

Từ kết quả thực nghiệm, có thể rút ra ba nhận xét chính. Thứ nhất, chiến lược **question_answer** đạt hiệu quả tốt nhất vì câu hỏi cung cấp ngữ cảnh cần thiết để diễn giải câu trả lời sinh viên. Thứ hai, HDBSCAN và BERTopic-style vượt trội hơn KMeans vì các misconception không nhất thiết có dạng cụm hình cầu và số cụm thực tế không cố định là 10. Thứ ba, BERTopic-style chỉ cải thiện metric nhẹ so với HDBSCAN nhưng có ưu thế lớn về khả năng giải thích nhờ

c-TF-IDF keyword extraction.

Với cấu hình mặc định `min_cluster_size = 5`, `min_samples = 3`, HDBSCAN tạo ra khoảng **10–15% noise points**. Các điểm này thường là câu trả lời sai đơn lẻ, không đủ phổ biến để hình thành một misconception có ý nghĩa giảng dạy.

CHƯƠNG 5 : ỨNG DỤNG DEMO VÀ MÔ TẢ TRIỂN KHAI HỆ THỐNG

5.1 Liên kết GitHub và demo triển khai

Phần demo của đề tài được xây dựng dưới dạng **website HTML tĩnh** và đã được triển khai lên nền tảng **Vercel**. Trong phần trình bày hệ thống, demo không được mô tả như một thành phần chỉ chạy cục bộ, mà được xem là bản triển khai trực tuyến của tầng trực quan hóa kết quả. Hai liên kết chính của hệ thống gồm:

GitHub repository:

Demo website:

Ứng dụng demo được phát triển dưới dạng website HTML tĩnh nhằm trực quan hóa kết quả của đề tài **Khai phá lỗi sai và mẫu hình sai lầm trong kiểm tra đánh giá dạng câu hỏi tự luận**. Hệ thống được triển khai tại địa chỉ . Người dùng có thể truy cập trực tiếp để xem bản đồ cụm lỗi sai, so sánh 9 cấu hình thực nghiệm và quan sát ví dụ câu trả lời sinh viên theo từng nhóm lỗi sai. Mã nguồn đầy đủ của hệ thống được công bố tại GitHub repository: .


Về mặt logic, demo HTML đóng vai trò là **tầng trực quan hóa kết quả**. Pipeline Python thực hiện xử lý dữ liệu, embedding, giảm chiều, phân cụm và đánh giá; sau đó các kết quả tổng hợp được dùng để hiển thị trên giao diện web. Vì vậy, demo không thay thế pipeline thực nghiệm mà là lớp trình bày kết quả cuối cùng dưới dạng dễ quan sát.

5.2 Kiến trúc hệ thống demo

Ứng dụng demo được xây dựng để minh họa trực quan quy trình khai phá lỗi sai và mẫu hình sai lầm trong câu trả lời tự luận. Giao diện thể hiện các thông tin chính như tổng số câu trả lời, số cấu hình thí nghiệm, số nhóm lỗi sai, cấu hình tốt nhất và các chỉ số đánh giá quan trọng.

Bảng 5.1. Công nghệ sử dụng trong ứng dụng demo

Thành phần	Công nghệ / Vai trò
Giao diện demo	HTML, CSS, JavaScript
Styling	CSS tùy chỉnh, giao diện dark theme
Visualization	UMAP scatter plot, biểu đồ so sánh cấu hình
Data display	Cluster detail, sample answers, configuration comparison
Deployment	Vercel
Mã nguồn	GitHub repository



Hình 5.1. Kiến trúc tổng quan ứng dụng demo và triển khai hệ thống

Luồng hoạt động có thể mô tả theo bốn tầng. Tầng thứ nhất là **dữ liệu đầu vào**, bao gồm các câu hỏi, câu trả lời tham chiếu, câu trả lời sinh viên và annotation lỗi sai. Tầng thứ hai là **xử lý thực nghiệm**, nơi Python pipeline thực hiện lọc dữ liệu, embedding, giảm chiều và phân cụm. Tầng thứ ba là **kết quả đầu ra**, gồm nhãn cụm, từ khóa đại diện, metric đánh giá và ví dụ câu trả lời. Tầng cuối cùng là **giao diện HTML demo**, dùng để trình bày kết quả dưới dạng trực quan.

5.3 Mô tả hệ thống và tư liệu đi kèm mã nguồn

Bên cạnh báo cáo lý thuyết và kết quả thực nghiệm, đề tài còn có phần tư liệu đi kèm mã nguồn nhằm giúp người đọc hiểu rõ hơn cách hệ thống được tổ chức và triển khai. Phần này mô tả cấu trúc dự án, luồng xử lý dữ liệu, schema chuẩn hóa, dữ liệu mẫu, cấu hình thực nghiệm và kết quả đầu ra. Nhờ đó, nghiên cứu không chỉ dừng lại ở phần trình bày thuật toán mà còn thể hiện được khả năng triển khai thành một pipeline hoàn chỉnh, có thể kiểm chứng và mở rộng trong các nghiên cứu tiếp theo.

5.3.1 Tổng quan đề tài

Đề tài **Khai phá lỗi sai và mẫu hình sai lầm trong kiểm tra đánh giá dạng câu hỏi tự luận** tập trung vào bài toán phát hiện, phân tích và nhóm các lỗi sai thường gặp trong câu trả lời tự luận ngắn của sinh viên. Thay vì chỉ phân loại câu trả lời là đúng hay sai như các hệ thống chấm điểm câu trả lời ngắn tự động, hệ thống nghiên cứu hướng đến việc phát hiện các nhóm câu trả lời sai có cùng nguyên nhân gốc rễ. Các nhóm này được gọi là **nhóm mẫu hình sai lầm**

hoặc *misconception clusters*.

Trong báo cáo này, khái niệm *misconception mining* được hiểu là quá trình khai phá các nhóm lỗi sai và mẫu hình sai lầm lặp lại trong câu trả lời tự luận của người học. Đây là hướng tiếp cận không chỉ quan tâm đến điểm số cuối cùng, mà còn tập trung vào việc nhận diện những kiểu hiểu sai có tính hệ thống để hỗ trợ phân tích, phản hồi và cải thiện quá trình dạy học.

Pipeline chính sử dụng **SBERT** để chuyển văn bản thành vector ngữ nghĩa, **UMAP** để giảm chiều dữ liệu, **KMeans/HDBSCAN/BERTopic-style** để phân cụm, sau đó dùng các metric nội tại và ngoại tại để đánh giá chất lượng cụm. Kết quả cuối cùng được trực quan hóa bằng giao diện HTML demo đã triển khai trên Vercel.

5.3.2 Cấu trúc thư mục dự án


Cấu trúc thư mục của hệ thống được tổ chức theo vai trò của từng thành phần như sau:

```
CSDL_Misconception_Mining/
  configs/
    misconception.yaml
    data.yaml
  data/
    raw/
    unified/
      data_generate.jsonl
      data_scraping.jsonl
  demos/
    index.html
  essays/
  experiments/
    phase3_misconception.py
  src/
    data/
    misconception/
    evaluation/
    utils.py
  tests/
  results/phase3/
  data-generate.csv
  data-scraping.json
```

Cách mô tả này giúp người đọc hiểu rằng hệ thống không chỉ có giao diện demo, mà còn có đầy đủ phần xử lý dữ liệu, pipeline thực nghiệm, đánh giá và kiểm thử.

5.3.3 Pipeline xử lý dữ liệu

Pipeline xử lý dữ liệu của hệ thống được triển khai theo luồng sau:



Hình 5.2. Pipeline xử lý dữ liệu của hệ thống khai phá lỗi sai và mẫu hình sai lầm

Trong đó, bước lọc dữ liệu chỉ giữ lại các nhãn `partially_correct_incomplete`, `contradictory` và `irrelevant`. Các nhãn `correct` và `non_domain` không được đưa vào quá trình khai phá lỗi sai vì không phản ánh trực tiếp các mẫu hình sai lầm cần phân tích.

5.3.4 Cơ sở dữ liệu và schema chuẩn hóa

Toàn bộ dữ liệu được chuẩn hóa về cấu trúc `UnifiedRecord`. Đây là schema trung tâm giúp các nguồn dữ liệu khác nhau có thể được đưa vào cùng một pipeline.

Bảng 5.2. Các nhóm trường chính trong UnifiedRecord

Nhóm trường	Trường tiêu biểu	Ý nghĩa
Identity	sample_id, source_dataset, original_id, question_id	Định danh bản ghi và nguồn dữ liệu
Domain	domain, subdomain, difficulty	Môn học, chủ đề và độ khó
Bộ ba ASAG	question, reference_answer, student_answer	Dữ liệu cốt lõi cho bài toán chấm điểm và phân tích lỗi sai
Nhân chấm điểm	score_raw, score_normalized, label_2way, label_3way, label_5way	Thông tin đánh giá câu trả lời
Annotation lỗi sai	misconception_tags, misconception_inventory, missing_concepts, extra_incorrect_claims	Cơ sở để đánh giá extrinsic và diễn giải lỗi sai
Feedback	feedback_short, feedback_detailed, feedback_type, feedback_tone	Phản hồi có thể dùng cho hệ thống hỗ trợ giáo viên/sinh viên
Metadata	split, is_human_annotated, is_synthetic, annotation_confidence	Quản lý nguồn, trạng thái và độ tin cậy của dữ liệu
Usability flags	usable_for_grading, usable_for_feedback, usable_for_misconception_mining, usable_for_robustness_eval	Xác định bản ghi dùng được cho nhiệm vụ nào

5.3.5 Dữ liệu mẫu

Một bản ghi dữ liệu sau khi chuẩn hóa có thể được biểu diễn như sau:

```
{
  "sample_id": "GEN_00042",
  "source_dataset": "data_generate",
  "question_id": "Q015",
  "domain": "physics",
  "subdomain": "mechanics",
  "difficulty": "medium",
  "question": "What is the relationship between force and acceleration?",
  "reference_answer": "Force equals mass times acceleration ( $F = ma$ ).",
  "student_answer": "Force and acceleration are the same thing, just measured in different units.",
  "label_5way": "contradictory",
  "misconception_tags": ["confuses_force_with_acceleration"],
  "missing_concepts": [" $F = ma$  relationship", "role of mass"],
  "extra_incorrect_claims": ["force and acceleration have same units"],
  "split": "train",
```

```

    "is_synthetic": true,
    "annotation_confidence": 0.92
}

```

Ví dụ này thể hiện rõ một câu trả lời sai dạng *contradictory*, trong đó sinh viên nhầm lẫn giữa lực và gia tốc. Nhãn *misconception_tags* đóng vai trò *gold label* khi đánh giá bằng NMI, ARI, Purity và V-measure.

5.3.6 Cấu hình thực nghiệm

Thiết kế thực nghiệm của hệ thống gồm 9 cấu hình, được tạo từ 3 chiến lược embedding và 3 phương pháp clustering.

Bảng 5.3. Ma trận cấu hình thực nghiệm trong phần mô tả hệ thống

Config	Embedding Strategy	Clustering Method	Ý nghĩa
C1	<code>answer_only</code>	KMeans	Baseline chỉ dùng câu trả lời sinh viên
C2	<code>answer_only</code>	UMAP + HDBSCAN	Kiểm tra hiệu quả density clustering
C3	<code>answer_only</code>	BERTopic-style	Thêm c-TF-IDF để giải thích cụm
C4	<code>question_answer</code>	KMeans	Bổ sung ngữ cảnh câu hỏi
C5	<code>question_answer</code>	UMAP + HDBSCAN	Kết hợp ngữ cảnh câu hỏi và phân cụm mật độ
C6	<code>question_answer</code>	BERTopic-style	Cấu hình tốt nhất trong thí nghiệm
C7	<code>full_triplet</code>	KMeans	Dùng cả câu hỏi, đáp án tham chiếu và câu trả lời sinh viên
C8	<code>full_triplet</code>	UMAP + HDBSCAN	Kiểm tra full context với density clustering
C9	<code>full_triplet</code>	BERTopic-style	Full context + từ khóa giải thích cụm

Các tham số cố định gồm `all-MiniLM-L6-v2`, UMAP `n_neighbors = 15`, `min_dist = 0.1`, `metric = cosine`, HDBSCAN `min_cluster_size = 5`, `min_samples = 3`, KMeans `n_clusters = 10`, `c-TF-IDF top_n_keywords = 5` và `seed 42`.

5.3.7 Kết quả đầu ra

Sau khi chạy thực nghiệm, kết quả được lưu trong thư mục `results/phase3/`. Các file đầu ra thể hiện kết quả của từng nhóm thí nghiệm và cho phép truy xuất lại kết quả tổng hợp.

```

results/phase3/
|-- global_grid_results.json
|-- granularity_results.json
|-- cluster_keyword_summaries.json
`-- phase3_all_results.json

```

Một kết quả mẫu của cấu hình tốt nhất được mô tả như sau:

```
{
  "strategy": "question_answer",
  "method": "bertopic",
  "granularity": "global",
  "n_samples": 6482,
  "n_clusters": 9,
  "intrinsic": {
    "silhouette": 0.42,
    "calinski_harabasz": 91.2,
    "davies_bouldin": 1.41
  },
  "extrinsic": {
    "nmi": 0.63,
    "ari": 0.49,
    "purity": 0.72,
    "v_measure": 0.61
  }
}
```

Kết quả này cho thấy `question_answer` là chiến lược hiệu quả nhất vì câu hỏi cung cấp ngữ cảnh cần thiết để phân biệt các lỗi sai; BERTopic-style đạt kết quả tốt vì kết hợp được UMAP, HDBSCAN và c-TF-IDF, vừa phân cụm vừa hỗ trợ diễn giải.

5.3.8 Vai trò của phần mô tả hệ thống

Phần mô tả hệ thống đóng vai trò kết nối giữa nội dung nghiên cứu và sản phẩm triển khai. Về mặt học thuật, nội dung này giúp làm rõ bài toán, dữ liệu, schema, pipeline, thiết kế thực nghiệm và kết quả đầu ra. Về mặt kỹ thuật, nó cho thấy hệ thống có cấu trúc rõ ràng, có thể kiểm chứng lại các bước xử lý chính và có khả năng mở rộng cho những nghiên cứu tiếp theo.

Trong bối cảnh tiểu luận thạc sĩ, phần mô tả hệ thống không tập trung vào các lệnh cài đặt hoặc hướng dẫn vận hành chi tiết như tài liệu dành cho lập trình viên. Trọng tâm của phần này là giải thích cách các thành phần trong hệ thống liên kết với nhau: dữ liệu được chuẩn hóa về `UnifiedRecord`, pipeline thực nghiệm thực hiện embedding và clustering, kết quả được lưu lại để đánh giá, và demo HTML trực quan hóa các nhóm lỗi sai và mẫu hình sai lầm được phát hiện từ dữ liệu câu trả lời tự luận. Cách trình bày này giúp người đọc hiểu được tính tái lập của nghiên cứu mà không làm báo cáo trở nên quá nặng nề về thao tác kỹ thuật.

Nhờ có phần tư liệu đi kèm mã nguồn, đề tài thể hiện được ba giá trị chính. Thứ nhất, nghiên cứu có tính minh bạch vì người đọc có thể đối chiếu giữa báo cáo, mã nguồn và demo triển khai. Thứ hai, nghiên cứu có tính tái lập vì pipeline, cấu hình và dữ liệu đầu ra được mô tả theo cấu trúc nhất quán. Thứ ba, nghiên cứu có tính ứng dụng vì kết quả phân cụm không chỉ được trình bày bằng bảng số liệu mà còn được trực quan hóa thành giao diện hỗ trợ quan sát và diễn giải các mẫu hình sai lầm.


5.4 Mô tả giao diện demo và trực quan hóa kết quả

Demo online hiển thị các thành phần chính: tổng số **10,000 câu trả lời**, **9 cấu hình thử nghiệm**, **6 nhóm lỗi sai**, và chỉ số **NMI tốt nhất = 0.63**. Quy trình trực quan trên demo gồm dữ liệu đầu vào, SBERT embedding, UMAP, HDBSCAN

và kết quả bản đồ lỗi sai. Giao diện cũng nhấn mạnh cấu hình tốt nhất là C6, với $NMI = 0.63$, $ARI = 0.49$, $Purity = 0.72$ và $V\text{-measure} = 0.61$.



Hình 5.3. Giao diện tổng quan demo khai phá lỗi sai và mẫu hình sai lầm trên Vercel



Hình 5.4. Giao diện bản đồ cụm lỗi sai UMAP và chi tiết nhóm

Hai hình trên minh họa cách hệ thống trình bày kết quả khai phá lỗi sai và mẫu hình sai lầm: phần tổng quan cho thấy quy mô dữ liệu, số cấu hình và cấu hình tốt nhất; phần bản đồ UMAP giúp quan sát trực quan các cụm lỗi sai và xem ví dụ câu trả lời đại diện theo từng nhóm.

CHƯƠNG 6 : KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 Kết luận

Tiểu luận đã trình bày một pipeline end-to-end cho bài toán khai phá lỗi sai và mẫu hình sai lầm trong câu trả lời sinh viên. Pipeline bao gồm các bước lọc dữ liệu, tạo embedding bằng SBERT, giảm chiều bằng UMAP, phân cụm bằng KMeans/HDBSCAN/BERTopic-style, đánh giá bằng intrinsic và extrinsic metrics, đồng thời trực quan hóa kết quả thông qua ứng dụng demo.

Kết quả thực nghiệm trên 9 cấu hình cho thấy **C6 – question_answer + BERTopic-style** là cấu hình tốt nhất. Cấu hình này đạt **Silhouette = 0.42**, **CH Index = 91.2**, **DB Index = 1.41**, **NMI = 0.63**, **ARI = 0.49**, **Purity = 0.72** và **V-measure = 0.61**. Kết quả này chứng minh rằng bổ sung ngữ cảnh câu hỏi giúp cải thiện rõ rệt chất lượng biểu diễn, trong khi BERTopic-style đem lại lợi thế về cả phân cụm và khả năng giải thích.

6.2 Hạn chế

Nghiên cứu vẫn còn một số hạn chế. Thứ nhất, mô hình embedding mới dùng ở all-MiniLM-L6-v2, chưa so sánh với các mô hình lớn hơn như all-mpnet-base-v2, instructor-xl hoặc e5-large-v2. Thứ hai, dữ liệu thực nghiệm chủ yếu là tiếng Anh, vì vậy khả năng áp dụng cho tiếng Việt cần được kiểm chứng thêm. Thứ ba, gold labels trong Data_Generate được sinh bằng LLM, chưa phải nhãn do chuyên gia giáo dục gán thủ công. Thứ tư, các siêu tham số như `n_neighbors`, `min_dist`, `min_cluster_size` được cố định, chưa tối ưu hóa bằng Grid Search hoặc Bayesian Optimization. Cuối cùng, nghiên cứu chưa có đánh giá định tính từ giáo viên hoặc chuyên gia giáo dục về ý nghĩa sư phạm của từng cụm. Ngoài ra, nghiên cứu mới sử dụng UMAP làm phương pháp giảm chiều chính, chưa so sánh với các kỹ thuật trực quan hóa dữ liệu phổ biến khác như t-SNE [15].

6.3 Hướng phát triển

Trong tương lai, nghiên cứu có thể mở rộng theo các hướng sau: thử nghiệm thêm các mô hình embedding lớn và đa ngôn ngữ; fine-tune SBERT trên dữ liệu ASAG; tối ưu hóa siêu tham số của UMAP và HDBSCAN; tích hợp pipeline vào hệ thống ASAG hoặc LMS; bổ sung đánh giá định tính từ giáo viên; mở rộng dữ liệu sang tiếng Việt; đồng thời nghiên cứu các phương pháp phân cụm nâng cao như spectral clustering, hierarchical clustering hoặc semi-supervised clustering.

TÀI LIỆU THAM KHẢO

- [1] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks,” in *Proceedings of EMNLP-IJCNLP*, Hong Kong, China, 2019, pp. 3982–3992.
- [2] L. McInnes, J. Healy, and J. Melville, “UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction,” arXiv preprint arXiv:1802.03426, 2018.
- [3] R. J. G. B. Campello, D. Moulavi, and J. Sander, “Density-Based Clustering Based on Hierarchical Density Estimates,” in *Advances in Knowledge Discovery and Data Mining*, LNCS, vol. 7819, Springer, 2013, pp. 160–172.
- [4] M. Grootendorst, “BERTopic: Neural topic modeling with a class-based TF-IDF procedure,” arXiv preprint arXiv:2203.05794, 2022.
- [5] M. O. Dzikovska *et al.*, “SemEval-2013 Task 7: The Joint Student Response Analysis and 8th Recognizing Textual Entailment Challenge,” in *Proceedings of SemEval 2013*, Atlanta, GA, USA, 2013, pp. 263–274.
- [6] M. Mohler and R. Mihalcea, “Text-to-text Semantic Similarity for Automatic Short Answer Grading,” in *Proceedings of EACL 2009*, Athens, Greece, 2009, pp. 567–575.
- [7] D. Hestenes, M. Wells, and G. Swackhamer, “Force Concept Inventory,” *The Physics Teacher*, vol. 30, no. 3, pp. 141–158, 1992.
- [8] P. J. Rousseeuw, “Silhouettes: A graphical aid to the interpretation and validation of cluster analysis,” *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.
- [9] T. Calinski and J. Harabasz, “A dendrite method for cluster analysis,” *Communications in Statistics - Theory and Methods*, vol. 3, no. 1, pp. 1–27, 1974.
- [10] D. L. Davies and D. W. Bouldin, “A Cluster Separation Measure,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. PAMI-1, no. 2, pp. 224–227, 1979.
- [11] A. Rosenberg and J. Hirschberg, “V-Measure: A Conditional Entropy-Based External Cluster Evaluation Measure,” in *Proceedings of EMNLP-CoNLL*, Prague, Czech Republic, 2007, pp. 410–420.
- [12] A. S. Lan, A. E. Waters, C. Studer, and R. G. Baraniuk, “Sparse Factor Analysis for Learning and Content Analytics,” *Journal of Machine Learning Research*, vol. 15, pp. 1959–2008, 2015.
- [13] T. Gong, Y. Yao, and X. Chen, “Automatic Misconception Detection in Student Responses Using BERT,” in *Proceedings of the 13th International Conference on Educational Data Mining*, 2020.
- [14] W. Wang, F. Wei, L. Dong, H. Bao, N. Yang, and M. Zhou, “MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers,” in *Advances in Neural Information Processing Systems*, 2020.
- [15] L. van der Maaten and G. Hinton, “Visualizing Data using t-SNE,” *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008.

CHƯƠNG A : LIÊN KẾT MÃ NGUỒN VÀ DEMO

Mã nguồn GitHub: https://github.com/vancevo/CSDL_Misconception_Mining

Demo triển khai trên Vercel: <https://csdl-misconception-mining.vercel.app/>